

pkulpgkwpdrfl.pdf

硕士研究生学位论文

题目：加权特征融合的轻量级中
药饮片检测算法研究

姓 名：_____

学 号：_____

院 系：_____

专 业：_____

研究方向：_____

导 师：_____

二〇二五 年 六 月

img/bqsm_180xxxxxxx.pdf

摘要

中文摘要部分...

关键词：A，B，C，D

Design and implementation of a XXXXX system based on XXXX

Zack Snyder (XXXX)

Directed by: Prof. XXX and Prof. YYY

ABSTRACT

英文摘要部分...

KEY WORDS: A,B,C,D

目录

第一章 绪论	1
1.1 研究背景与意义	1
1.2 国内外研究现状	2
1.2.1 基于传统机器学习的中药饮片检测	2
1.2.2 基于深度学习的中药饮片检测	3
1.3 主要研究内容	4
1.4 论文结构安排	5
第二章 相关工作及基础理论知识	7
2.1 卷积神经网络	7
2.1.1 卷积层	7
2.1.2 池化层	8
2.1.3 全连接层	9
2.1.4 激活函数	9
2.1.5 损失函数	11
2.2 注意力机制	12
2.3 基于深度学习的目标检测算法	14
2.3.1 两阶段目标检测算法	14
2.3.2 一阶段系列目标检测算法	16
2.4 轻量级模型介绍	21
2.5 本章小结	22
第三章 数据集构建以及基准模型选取	23
3.1 引言	23
3.2 中药饮片图像采集	24
3.3 数据增强	25
3.3.1 Random 随机增强	25
3.3.2 Mixup 数据增强	25
3.3.3 Mosaic 数据增强	26
3.4 数据集标注及划分	27
3.5 本章小结	27

第四章 基于改进 YOLOv8 的中药饮片检测模型	29
4.1 引言	29
4.2 基于改进多维度动态卷积的特征提取	29
4.3 基于卷积和注意力融合 CAFM 的改进	31
4.4 基于 NWD 的标签分配与损失函数改进	33
4.5 实验设计与结果分析	35
4.5.1 实验数据集	35
4.5.2 实验平台及参数设置	35
4.5.3 评价指标	36
4.5.4 消融实验	37
4.5.5 对比实验	37
4.6 本章小结	37
第五章 改进的轻量化中药饮片检测模型	39
5.1 引言	39
5.2 基于多尺度特征融合的轻量级中药饮片检测模型改进	39
5.2.1 基于蛇形动态卷积 DSConv 的改进与替换	39
5.2.2 引入渐进特征金字塔网络 AFPN 进行多尺度特征融合	40
5.2.3 轻量化主干网络	41
5.2.4 改进后的整体网络架构	43
第六章 总结和展望	45
6.1 总结	45
6.2 展望	45
参考文献	47
致谢	49
北京大学学位论文原创性声明和使用授权说明	51

表格索引

表 3.1	TCMDP40 数据集类别.....	24
表 4.1	实验训练参数.....	36
表 4.2	实验环境	36

插图索引

图 2.1	卷积运算过程	8
图 2.2	池化操作	9
图 2.3	常用激活函数图像	10
图 2.4	通道注意力模块	13
图 2.5	空间注意力	13
图 2.6	RCNN 模型结构	15
图 2.7	Faster R-CNN 模型结构图	16
图 2.8	YOLO 流程检测图	17
图 2.9	YOLOv2 模型提升部分	17
图 2.10	Darknet 与其他网络结构对比	18
图 2.11	FPN 网络结构	19
图 2.12	yolov8 整体框架图	21
图 3.1	数据集构建流程图	23
图 3.2	部分中药饮片图像	25
图 3.3	Mixup 数据增强效果图	26
图 3.4	Mosaic 数据增强效果图	27
图 4.1	全维度动态卷积（待修改成横向的结构）	30
图 4.2	改进 c2f（待修改）	31
图 4.3	改进 yolov8 架构（待修改）	31
图 4.4	后续补复杂背景影响识别的图	32
图 4.5	CAFM 结构图（待修改）	32

第一章 绪论

1.1 研究背景与意义

近年来，随着中医药在疫病防治中的有效性日益凸显，以及人口老龄化背景下慢性病、老年病诊疗需求的快速增长，我国将中医药发展提升至国家战略高度，先后颁布《中医药法》《“十四五”中医药发展规划》等政策文件，明确提出推动中药饮片标准化、现代化生产及信息化追溯体系建设。作为中医药体系的核心组成部分，中药饮片是中药材经传统工艺炮制加工后的用药成品，常常呈现管状、颗粒状和切片状，它们承载着中华民族数千年的医药智慧，种类极为庞杂，仅《中华本草》记载的饮片类型就超过 12800 种。

中药饮片既是中医临床调配与制剂生产的关键原料，也是药食同源的重要载体，其质量直接关系公众健康与产业发展。然而，中药饮片行业长期面临质量管控难题，据 2024 年国家药监局抽检数据显示，约 15% 的不合格饮片源于形态或杂质误判，所以，中药饮片质量检测行业智能化升级的紧迫性日益凸显。

目前，中药饮片生产仍受限于标准化程度低、人工分拣误差率高等瓶颈制约，传统分拣模式难以满足企业规模化生产的需求。一方面是传统的人工鉴别依赖医师的经验或者图文对照，但是由于中草药的生长地域、生理形态等因素，炮制饮片的形态千差万别，个人的经验和知识终究有限，所以效率低而且误判率高；另一方面，现有的基于机器学习的饮片识别研究虽然有所进展，但是存在特征提取方式设计复杂、算法精度不足、泛化性弱等问题，难以实现精准检测。此外，低效的饮片检测方式无法检验出以次充好、形态混淆的假冒伪劣产品，再加上常人欠缺辨别中药的专业知识，多重因素导致市场上中药饮片质量参差不齐、假货横行，这不仅直接影响中医治疗的临床疗效与用药安全，还间接影响我国中医药行业的长远发展。在这种情况下，亟需研发一种高效且精准的中药饮片检测方法。

当前主流的目标检测方式是依托深度学习神经网络架构，首先通过标注数据训练模型，然后提取特征识别目标位置与类别，最终经过后处理输出检测结果。现有目标检测算法多聚焦于行人、交通工具、工业设备等通用目标的识别任务，然而不同目标的形态特征与应用场景差异显著，对于模型来说有不同的设计要求。所以，针对中药饮片的检测，由于其种类繁多、类间差异小、形态复杂并且大小不一，传统特征提取方法难以精准区分，就需要对现有的目标检测模型进行进一步的实验和探索。另外，中药饮片检测领域缺乏标准的图像数据集，以至于算法训练面临样本多样性不足与泛化能力受限的制约。因此，构建多种类的中药饮片数据集，并研究适配其形态和纹理特

性的目标检测模型，不仅具有巨大的实用价值，能够推动中药产业智能化升级，还是对国家“十四五”中医药发展规划的响应，而且也可以为后续的研究打下基础。

1.2 国内外研究现状

1.2.1 基于传统机器学习的中药饮片检测

中药饮片鉴别长期依赖“眼看、手摸、鼻闻、口尝”的传统经验法，存在主观性强、标准化程度低的问题。20 世纪末，计算机视觉技术开始萌芽，国内 Liang 等 (1998) 首次尝试将红外光谱与 SVM 结合，对人参根系进行初步分类，但由于硬件限制（当时 GPU 计算尚未普及）及算法复杂度高（需要手动提取光谱特征），准确率仅达 65% 左右

在图像识别领域，较早的算法采用的是机器学习方法，通常步骤为预处理图像、提取特征、编码特征和训练分类模型。传统的机器学习算法指的是浅层机器学习算法，例如决策树、朴素贝叶斯、KNN、SVM 和聚类算法。Hunt 等研究人员^[1]最先研究决策树算法，是其他决策树算法（ID3、C4.5、CART）的基础。决策树算法主要针对分类任务，主要是对数据样本特征构建分支不同的树形结构。它不需要对数据进行先验假设，解释性和稳健性强，计算速度快。兰济乐等人^[2]基于 SPSS 统计软件结合决策树等算法对中药治疗癫痫的成方规律进行分析，能对抗癫痫方剂成方的规律充分挖掘，并基于此进行药物开发。随后托马斯·贝叶斯提出了朴素贝叶斯算法，该算法对输入数据的表达形式要求很高，多用于分类和定量式训练任务。钱丹丹等人^[3]基于朴素贝叶斯和计算机视觉相关技术构建中药饮片系统，可以快速的对中药饮片进行分级。1967 年 Thomas^[4]提出 KNN 算法，此算法对样本进行划分的依据是最近邻的一个或者几个样本类别。该算法简单易于理解，既可作分类也可作回归，无需进行训练。但存在样本不平衡的问题。王新洲及其同事^[5]从反应数据库收集到数据后，利用 KNN 算法和 SVM 构建模型，经过验证，可以很好地对药物成分进行预测。1995 年 Corinna 等人^[6]提出 SVM 算法，SVM 是监督式学习算法，广泛的应用于分类和回归等分析问题中。SVM 计算简单，既可以用于线性问题，也可用于非线性问题。但对参数和核函数要求较高。任建峰^[7]在二分类 SVM 的基础上构造了多类 SVM，对多个自然图像进行分类，分类准确率大大提升。孙慧婷^[8]提出用 DBT-SVM 算法对中药材牡丹皮规格进行分类，实验结果证明 DBT-SVM 算法准确率远高于传统 SVM 算法。传统机器学习算法可以快速的处理小样本数据集，但一些机器学习算法要求矩阵特征值或奇异值分解，时间复杂度高，对于海量的数据难以处理。很多传统的机器学习算法无法和 GPU 算力结合进行并行计算，无法处理大规模数据，导致识别效果差难以在实际系统中应用^[9]。

1.2.2 基于深度学习的中药饮片检测

基于理化特征和图像特征的中药材检测识别都或存在一定的缺陷,难以推广到实际应用。近年来,深度学习在交通、农业、工业和医疗的结合屡见不鲜,国家鼓励人工智能促进中医药发展,深度学习与中药材识别也开始结合。孙等^[7]训练 VGG 16 卷积神经网络实现中药饮片识别,可以达到 70% 的准确度。徐飞^[8]等人基于 GoogleNet 卷积神经网络对人参西洋参饮片进行识别,并通过正交设计确定最优参数,准确率达到 90% 以上。刘伟等人^[9]提出基于 DensenNet 和 Xception 融合中药材识别模型,结合数据增强、迁移学习和融合模型等技巧,分类准确度达到了 99.65%。史等人^[10]基于 GoogleNet 构建了金银花仿野生种植识别模型,结合该模型提取到的空间种植信息,实现对金银花的精细化分类。通过对上述文献的梳理发现,目前深度学习与中药饮片的辨识主要集中于分类,目标检测较少,这仅仅适用于单一种类中药饮片辨识的情况,对于中药饮片的多分类目标检测与识别无法适应。本文针对多分类中药饮片进行定位与分类,可为目标检测在中药材识别相关领域的研究提供更多的支持。

本节主要介绍卷积神经网络算法的发展及相关应用,为后面中药饮片图像识别研究提供基础。1989 年 Yann LeCun 等人提出的 LeNet 网络,是卷积神经网络中最经典的网络模型^[11]。LeNet 主要应用于 MNIST 数据集中手写数字的识别,并且取得了不错的准确率,从此深度学习开始被人们所熟知,其模型结构如图 1-1 所示。尽管神经网络和深度学习的概念已经存在了几十年,但在实际的应用中的效果通常不如传统的机器学习方法。2012 年 AlexNet^[12]的出现彻底改变了这个局面,AlexNet 在 ILSVRC 比赛中以远超第二名的优势取胜并迅速引起广泛关注,从而开启了卷积神经网络在视觉任务中广泛应用的新纪元。后续提出的 VGGNet^[13]、GoogLeNet^[14]、ResNet^[15]等都在视觉任务中取得了令人瞩目的成绩。很多学者将卷积神经网络用于解决现实中的问题。Hassan 等人^[16]基于 inception 层和残差连接构建一种新模型,使用深度可分离卷积来减少参数数量。该模型在三个不同的植物疾病数据集上进行了训练和测试,分别取得了 99.39%、99.66%、76.59% 的准确率,与其他先进的深度学习模型相比,提出的模型在参数数量更少的情况下达到了更高的准确率。Bae 等人^[17]在 Inception-v4 架构的基础上进行了一些关键性修改,以适应阿尔茨海默病(AD)识别的特定需求,将病人的年龄、性别和冠状切片的编号作为附加特征融入到最终的分类器中,模型在内部数据集验证中达到的平均 AUC 为 0.91-0.94。许景辉等人^[18]在 VGG-16 模型的基础上设计添加了新的全连接层,对 3 种玉米病虫害进行图像采集,最终实现对复杂田间背景下的玉米病虫害图像的成功识别,平均准确率为 95.33%。傅隆生等人^[19]以田间多簇猕猴桃为研究对象,以 LeNet 卷积神经网络为基础并对模型结构进行优化,最终成功实现对田间多簇猕猴桃的有效识别。CNN 可以快速、自动、准确的识别图像,不少研究者将其应

用在中药饮片识别问题上。孙鑫等人^[20]构建包含 50 种常用的中药饮片数据集，鉴于数据集规模较小，利用 ImageNet 数据集对 VGG-16 模型进行预训练，随后将其迁移至自己的数据集进行进一步训练。最终在 50 种中药饮片数据集上实现 70% 的识别精度。吴冲等人^[21]以川贝母，山楂及半夏饮片为研究对象，建立图像数据集，作者在网络深度方面参考了经典的 VGG-16 网络，但由于继续加深网络会带来网络退化的问题，实验又参考 ResNet 引入残差模块，为了避免过拟合在池化层之后使用 DropOut 函数，最后输出层使用 Softmax 函数进行分类。针对 11 种不同饮片图像的分类准确率达到 99%，而对于每一个具体类别的识别，其平均准确度也稳定在 97% 以上，展现出了出色的分类效果。徐飞等人^[22]构建人参与西洋参的数据集，并对模型的学习率、动量系数、批尺寸以及权值衰减系数进行了细致的优化。以 GoogLeNet 为基础，对模型超参数进行了针对性的优化和调整。最终识别率达到 90.9%，可快速区分人参与西洋参。王健庆等人^[23]构建常用中药饮片图像数据库，预先在 ImageNet 数据集训练得到 GoogLeNet 模型，再迁移到自己的数据训练，并对模型结构进行了进一步调整，最终平均识别率达到 92%。张等人^[24]^[38]采集大黄饮片并拍摄构建数据库，并对数据集图像进行灰度处理、高斯滤波等操作，然后通过 LBP 提取特征，得到大黄纹理图。以 VGG-16 模型为基础，修改后三节全连接层的节点数，使用迁移学习的方法进行微调，最终平均识别率为 93.42%。刘加峰等人^[39]采用 SSD (single-shot multibox detector) 模型，能够识别输入图片中的多种药材，并可以框出饮片在图片中的位置。使用 VGG-16 作为前置网络，使用卷积层替换全连接层。通过整合各层卷积输出的带有预测定位和置信度的特征映射，实现了对药材的高效识别。对（陈皮、甘草、枸杞）三种饮片进行识别验证，最终平均识别率可到 86.8%。李等人^[25]针对 AlexNet 网络在中药饮片图像识别中准确率低、鲁棒性差的问题，提出一种改进的卷积神经网络模型，通过缩减卷积核尺寸与数量、引入全局平均池化替代全连接层、批量归一化、Lion 优化算法、Mish 激活函数及 SENet 通道注意力机制，优化网络结构并减少参数。实验采用 50 种中药饮片的 8 倍扩充数据集，结果显示改进后模型平均识别率提升 6.1%，损失率下降 14.4%，参数量由 60M 缩减至 1M，显著提升了识别精度与训练效率，为中药饮片自动化识别提供了有效解决方案。

1.3 主要研究内容

由于中药饮片种类繁多、形态各异，传统机器学习方法难以有效捕捉饮片多层次纹理之间的细微差异。随着人们在医疗和生活中对于中药的需求越来越高，以往基于中药饮片的物理或者化学性质的检测手段也已经不合时宜。随着技术的发展，基于深度学习的检测方法越来越高效，但现有的目标检测方法在应用到中药饮片时存在显著

的适应性缺陷，主要存在以下几个问题：一是饮片纹理的渐变特征难以被常规卷积网络捕捉，枝叶状蜷曲形态的饮片存在漏检、误检的现象。二是饮片的大小尺度不一，并且存在密集堆叠现象，导致模型的检测精度不佳。三是医疗分拣设备算力受限与对饮片检测的实时性需求存在矛盾，目前的中药饮片检测方法的轻量化尚有不足。针对上述问题，本文提出融合渐进特征学习与模型轻量化的协同解决方案，具体工作内容如下：

(1) 构建中药饮片图像数据集。由于中药饮片识别领域缺乏适用于目标检测的图像数据集，本文通过拍摄采集与图像增强策略构建了一个包含 40 种常用中药饮片的图像数据集 TCMDP40，并且使用 Python 爬虫从各大搜索网站爬取饮片图像作为补充，为后续算法研究提供了可靠的数据基础。

(2) 构建渐进特征融合的精准检测模型。针对中药饮片纹理复杂、尺度差异显著的核心问题，本文设计一种渐进式特征融合网络架构 AFPCN，该架构先通过构建三级跨层融合路径与自适应空间加权机制，实现从微观纹理到宏观形态的递进式特征表达。然后通过卷积注意力融合模块 CAFM 增强对关键纹理特征的聚焦能力。为进一步适应尺寸多样性，引入全维度动态卷积 ODConv。在损失函数层面，融合归一化 Wasserstein 距离 NWD 与 CIoU 指标，通过高斯分布建模边界框几何特性，缓解堆叠饮片的定位模糊问题。

(3) 通用性适配优化与轻量化改进。针对管状饮片特征提取效率不高的问题，引进蛇形卷积生成自适应卷积路径，降低钩藤等弯曲、蜷缩饮片的定位误差，提高模型对于中药饮片的通用检测能力。针对医用分拣设备算力不足的问题，设计一种 MBE 轻量化主干网络，通过深度可分离卷积、改进型 ECA 注意力与倒残差结构的协同优化，合理压缩模型参数量。

1.4 论文结构安排

本文的研究内容主要分为六个章节来展开论述：第一章：绪论。主要介绍中药饮片检测的研究背景与意义，简要概括关于国内外对于这项研究进展，并且对于本文的研究内容和方法进行简单介绍。

第二章：相关工作及基础理论知识。首先对于卷积神经网络的基本概念进行介绍，并对于深度学习常用技术包括注意力机制和特征融合方式进行阐述，然后对基于深度学习的目标检测算法进行分类介绍，最后阐述一些轻量级模型的相关原理。

第三章：数据集构建以及基准模型选取。首先介绍对于中药饮片图像数据的拍摄采集工作，然后介绍利用 Python 爬虫丰富数据多样性的工作，接着使用图像增强技术扩充数据集。最后通过在本文所构建的数据集上做对比实验，选取表现良好的模型，作

为后续研究工作的基准模型。

第四章：构建渐进特征融合的精准检测模型针对切片状和颗粒状中药饮片纹理复杂，尺度大小不一，并且产生堆叠现象，检测精度低的问题，本文选取 yolov8 作为基准模型，设计了一种基于融合注意力机制的渐进特征融合网络，该方法首先构建渐进融合特征金字塔网络 AFPN，然后引进融合注意力模块 CAFM 增强语义信息，为了适应中药饮片尺寸大小不一的问题，还引入全唯动态卷积 OD 进行卷积方式的改进，更好的适应饮片大小尺寸，和复杂特征纹理。另外针对 YOLOV8 的 CIoU 损失函数在中药饮片检测中的局限性，引入引入归一化 Wasserstein 距离 NWD 作为部分替代指标，并且利用权重参数来对 CIoU 和 NWD 度量值的贡献比例进行控制，对两者进行加权平均，从而获得改进的损失函数。这些改进能够综合提升模型检测。

第五章：模型通用性适配与轻量化改进针对管状饮片特征提取效率不高的问题，引进蛇形卷积生成自适应卷积路径，降低钩藤等弯曲、蜷缩饮片的定位误差，提高模型对于中药饮片的通用检测能力。针对医用分拣设备算力不足的问题，本文对精准模型进行轻量化改进，首先设计一种 MBE 轻量化模块作为主干网络，该设计包含深度可分离卷积和改进的 ECA 注意力模块（损失函数替换为 hsigmod），在缩减模型参数的同时保持模型的精度。

第六章：总结和展望对本文的工作进行全面总结，指出一些不足之处，针对这些不足进行理论分析以及描述对于未来研究方向的展望。

第二章 相关工作及基础理论知识

本文的研究目标是通过运用一系列深度学习技术来提高中药饮片检测的精度与速度，本章将系统梳理深度学习相关的理论知识与技术演进，包括卷积神经网络、注意力机制、特征融合策略、目标检测算法以及轻量化模型。

2.1 卷积神经网络

卷积神经网络（Convolutional Neural Network, CNN）通过层级化结构实现特征抽象与空间建模，其核心组件包括卷积层、池化层、全连接层、激活函数与损失函数，各模块协同工作形成端到端的特征学习框架。

2.1.1 卷积层

卷积层是 CNN 的核心运算单元，通过卷积核（Kernel）的局部滑动提取空间特征。其数学形式可以表达为：

$$y_{i,j} = \sum_{m=0}^{k-1} \sum_{n=0}^{k-1} w_{m,n} \cdot x_{i+m,j+n} + b \quad (2.1)$$

其中 $w_{m,n}$ 是卷积核权重， x 是输入特征图， b 是偏置项， k 是卷积核尺寸。在卷积层中，输入数据和卷积核进行卷积运算，生成一组卷积特征。具体而言，卷积操作运算是将卷积核的参数与输入数据上对应位置的元素相乘，然后将所有乘积结果加起来，得到一个单一的值，也称为卷积特征中的一个像素值。下面以图2.1为例，对卷积操作进行说明：假设输入图像的尺寸为 5×5 ，并使用 3×3 的卷积核进行卷积，移动步长 S （Stride）为 1，通过输入图像的黄色部分与绿色卷积核进行对位相乘，得到一个乘积结果。再重复上述操作，将卷积核在输入图像上移动，每次移动一个步长进行新的乘积操作，重复上述过程，遍历输入图像的所有位置，最终得到尺寸为 3×3 输出的图像。当卷积移动到边缘处时，经常会出现超过边界的情况，通常用 0 来进行边缘填充（Padding）使得卷积过程顺利完成。假设输入图像的长度为 H_1 ，宽度为 W_1 ，卷积核长和宽分别为 F_H 和 F_W ，移动步长为 S ，边缘填充尺寸为 P ，经过卷积操作后输出图像的长度 H_2 和宽度 W_2 分别为：

$$H_2 = \frac{(H_1 - F_H + 2P)}{S} \quad (2.2)$$

$$W_2 = \frac{(W_1 - F_W + 2P)}{S} \quad (2.3)$$




图 2.1 卷积运算过程

在上述操作中只使用了一个卷积核，意味着只能提取单一的特征，只适用于简单的特征提取任务，只能在局部范围内进行感知，无法全局地考虑图像或序列的上下文信息，故一般采用多核卷积。多核卷积还可以增加网络的深度，通过在不同层使用多个卷积核，可以构建更深的网络结构，从而提高网络的表达能力。通过多核提取到的特征进行组合又形成新的特征，得到的图称为特征图。

2.1.2 池化层

池化层（Pooling layer）通过对局部输入区域的聚合操作来提取输入特征的主要信息，减小输入数据的空间尺寸。池化层通常位于在卷积层之后，或者在卷积层之间，用于减少卷积层输出的维度和模型中的参数量，降低计算的复杂度。常见的池化操作有最大池化（Max Pooling）和平均池化（Average Pooling）。最大池化是将池化区域内的最大值作为输出，这样可以保留输入特征的主要信息。而平均池化则是通过计算池化区域内的平均值进行输出，这样可以保留数据特征并减小噪声的影响。池化层的参数通常是窗口的大小 F 和步长 S 。窗口的大小决定了聚合操作的范围，而步长决定了滑动窗口的跨度。输入图像的大小为 W ，通过池化操作之后的输出大小设为 W_{out} ，其结果由公式2.4可得。常见的池化层是将尺寸设置为 2×2 和步长为 2，通过池化后可以将输入特征图的尺寸减半，如图2.2所示，各颜色区域内计算出最大值和平均值，并分别进行输出，最终得到的特征图尺寸减半。

$$W_{out} = \frac{(W - F)}{S} + 1 \quad (2.4)$$




图 2.2 池化操作

2.1.3 全连接层

全连接层 (Fully Connected Layer, FC) 作为深度神经网络中的关键组件，承担着整合抽象化前序层级特征表达的核心职能。其运作机制基于全局权值关联原则，通过构建输入特征向量与输出神经元之间的密集连接矩阵，实现多维特征空间的非线性映射。数学上可表述为：

$$Y = \sigma(WX + b) \quad (2.5)$$

其中， W 为高维权重矩阵， X 为输入特征向量， b 为偏置项， σ 代表非线性激活函数 (如 ReLU 或 Sigmoid)。该层级通过参数优化过程学习特征间的非线性组合规律，其强大的表征能力源于对输入特征全域关联性的建模。在典型网络架构中，FC 层常作为分类器置于网络末端，通过 Softmax 函数将高维特征投影至类别概率空间，完成从特征提取到决策输出的关键转化。

在图像分类任务中，FC 层与卷积层的协同作用体现了分层特征处理的优势。以经典 CNN 架构为例，卷积层通过局部感受野逐层提取图像的边缘、纹理等局部特征，而全连接层则整合这些分布式特征形成全局语义表征。这种层级关系体现了深度学习模型从局部到整体的认知模拟过程，如在 AlexNet 中，最后的全连接层将 4096 维特征向量映射至 1000 类 ImageNet 分类任务。

2.1.4 激活函数

一般地，卷积层和池化层产生线性输出，因此增加层数并不能显著提高神经网络的效率。由于图像信息呈非线性分布，因此神经网络需要非线性变换。加入非线性激活函数后，神经网络就可以直接学习到光滑的曲线来分割特征面，而不是用复杂的线

性组合来逼近光滑曲线，这使得神经网络的表示能力更强了，能够更好的拟合目标函数。经常使用的一些激活函数主要有 Sigmoid 函数、Tanh 函数以及 ReLU 函数等。(1)




图 2.3 常用激活函数图像

Sigmoid 函数 Sigmoid 函数是一个易于微分和优化的单调增长函数，函数图像如图2.3中的蓝色曲线，当 x 趋于无穷时， y 会无限接近 0 或 1，在整个实数域上都是平滑和连续的函数，这有利于进行概率解释和二分类问题的处理，其数学表达式如下所示：

$$f(x) = \frac{1}{1 + e^{-x}} \quad (2.6)$$

(2) **Tanh 函数**与 Sigmoid 函数相似，Tanh 函数图像也是一个 S 形曲线，为图2.3中的橙色曲线。但是 Tanh 函数的输出值在-1 到 1 区间，它可以产生负数的输出，这使得 Tanh 函数在处理中心化数据时更为适用，而且 Tanh 函数在输入接近 0 时具有更大的斜率，意味着它更容易激活神经元，其表达式见式2.7。当输入的绝对值较大时，Tanh 函数输出会饱和到 ± 1 ，这导致梯度下降算法在反向传播过程中容易陷入梯度饱和的问题，致使梯度消失。因此神经网络中更常用的是其他激活函数，如 ReLU。

$$f(x) = \frac{\sinh(x)}{\cosh(x)} = \frac{e^x - e^{-x}}{e^x + e^{-x}} = \frac{e^{2x} - 1}{e^{2x} + 1} = 2\text{sigmoid}(2x) - 1 \quad (2.7)$$

(3) **ReLU 函数** ReLU 激活函数是近年来在卷积神经网络中最常用的激活函数之一。ReLU 函数的数学公式如2.8所示，当 x 比 0 大时输出自身值，比 0 小时输出为 0，这样做的好处是让未激活的神经元不传递任何信号，从而实现了部分神经元的稀疏激活，这也有助于减少参数的数量，提高计算效率，函数曲线图如图2.3中的绿色曲线所示。

$$f(x) = \max(0, x) = \begin{cases} 0 & x \leq 0 \\ x & x > 0 \end{cases} \quad (2.8)$$

另外，ReLU 函数的导数在输入大于 0 时为 1，输入小于等于 0 时为 0，这种简单的导数计算方式有助于梯度下降算法的高效计算。

2.1.5 损失函数

损失函数 (loss function) 的目的是评估模型真实值与预测值之间的差异；通过最小化损失函数，模型的性能得以最大化。选择一个更合适的损失函数对于提高模型的预测准确性至关重要。目前，常见的损失函数有如下几种：

(1) 均方差损失函数均方差损失函数是一种常见的回归任务损失函数。均方差损失函数通过测量模型预测值和实际值之间的方差来评估模型的拟合程度。MSE 值越低，表示预测值和实际值误差越小，模型效果越好。它可以直观反映模型是否能够很好地匹配和解释观测数据，是评判回归和其他机器学习算法性能的重要技术指标之一。表达式如2.9所示

$$L = \frac{1}{2n} \sum_{i=1}^n \|\hat{y}_i - y_i\|^2 \quad (2.9)$$

其中， n 表示总样本数量， $\hat{y}_i$ 表示样本的预测输出，而 y_i 是其实际输出。

(2) 交叉熵损失函数在处理多目标分类问题时，通常会使用交叉熵损失函数。不过，在二元分类任务中，只有两个类别，损失函数也被称为二元交叉熵损失。交叉熵的通用表达式如式2.10所示，二元交叉熵损失的表达式如式2.11所示：

$$L = -\frac{1}{n} \sum_{i=1}^n \sum_{j=1}^c y_{ij} \ln \hat{y}_{ij} \quad (2.10)$$

$$L = -\frac{1}{n} \sum_{i=1}^n \mathcal{Y}_i \ln \hat{\mathcal{Y}} - (1 - \mathcal{Y}_i) \ln (1 - \hat{\mathcal{Y}}) \quad (2.11)$$

(3) CIoU 损失函数对于目标检测任务而言，CIoU 损失函数是一种重要的损失函数。它主要用于检测算法的输出层，对生成的边界框进行分类和回归分析。其表达式如式2.12所

示：

$$CIoU = IoU - \frac{D_2^2}{D_c^2} - \alpha v \quad (2.12)$$

其中，IoU 代表交并比， α 代表权重函数， v 代表长宽比的相似性， D_2^2 代表预测框与真实框中心点之间的距离， D_c^2 代表真实框和预测框的最小闭包的对角线距离。在边界框的回归预测中，中心坐标信息被视为一个单独的变量，这导致均方误差损失函数出现了问题。CIoU 损失函数成功地解决了均方误差函数的这一缺点。

2.2 注意力机制

深度学习中的注意力机制（Attention Mechanism）是一种模仿人类视觉和认知系统的方法，它允许神经网络在处理输入数据时集中注意力于相关的部分。通过引入注意力机制，神经网络能够自动地学习并选择性地关注输入中的重要信息，提高模型的性能和泛化能力。与传统神经网络的全连接或固定卷积操作不同，注意力机制通过可学习的权重参数实现特征的自适应筛选，有效缓解了长距离依赖问题和噪声干扰。

(1) 自注意力机制

自注意力机制是 Transformer 架构的核心组件，其本质是通过动态权重分配实现序列元素的全局依赖建模。从数学形式化角度，注意力机制可定义为对输入特征的多尺度动态加权过程。给定输入序列 $X \in \mathbb{R}^{L \times d}$ （ L 为序列长度， d 为特征维度），自注意力机制通过线性变换生成查询（Query）、键（Key）、值（Value）三个矩阵，计算过程如下：

$$Q = XW_Q, \quad K = XW_K, \quad V = XW_V \quad (2.13)$$


其中， $W_Q, W_K \in \mathbb{R}^{d \times d_k}, W_V \in \mathbb{R}^{d \times d_v}$ 为可训练参数矩阵。注意力权重的计算采用缩放点积形式：

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (2.14)$$

其中 d_k 为缩放因子^[26]，它的引入是为了解决点积结果量级随维度增长而膨胀的问题，避免 softmax 函数梯度消失。自注意力机制通过 QK^T 计算序列元素间关联强度，形成 $L \times L$ 的注意力矩阵，使模型能够自主强化关键区域的特征响应，然后用 softmax 函数沿行方向进行权重归一化，最后通过加权求和 V 矩阵获取上下文感知表示。虽然自注意力计算复杂度为 $O(L^2d)$ ，在短序列场景下效率优异，但是对长序列需结合稀疏注意力进行优化。

(2) 通道注意力机制

通道注意力机制 (Channel Attention Mechanism, CAM) 将特征图的每个通道都视为一个特征检测器，通过特征内部之间的关系来产生通道注意力特征图，聚焦于图像中有用的信息是”什么”，其模块结构如下图所示：




img/第二章图/通道注意力模块.jpg

图 2.4 通道注意力模块

可以看到，通道注意力的思路流程为：首先，对一个尺寸为 $H \times W \times C$ 的输入特征图进行空间维度的全局最大池化和全局平均池化，得到两个 $1 \times 1 \times C$ 的特征图。然后，将全局最大池化和全局平均池化的结果，分别送入一个共享的多层感知机 (MLP) 中学习，得到两个 $1 \times 1 \times C$ 的特征图。为了降低计算参数，在 MLP 中采用一个降维系数 r ，则 MLP 的第一层神经元个数为 C/r ，激活函数为 Relu，第二层神经元个数为 C 。最后，将 MLP 输出的结果进行 Add 操作，接着经过 Sigmoid 激活函数的映射处理，最终得到通道注意力权重矩阵 M_c 。

(3) 空间注意力机制

不同于通道注意力，空间注意力 (Spatial Attention Mechanism, SAM) 通过对特征图空间内部的关系来产生空间注意力特征图，聚焦于特征图上的有效信息在”哪里”，其模块结构如下图所示：空间注意力的思路流程是：首先，对一个尺寸为 $H \times W \times C$ 的



img/第二章图/空间注意力.jpg

图 2.5 空间注意力

输入特征图 F 进行通道维度的全局最大池化和全局平均池化，得到两个 $H \times W \times 1$ 的特征图；然后将全局最大池化和全局平均池化的结果，按照通道拼接 (concat)，得到特征图尺寸为 $H \times W \times 1$ ；最后，对拼接的结果进行 7×7 的卷积操作，得到特征图尺寸为 $H \times W \times 1$ ，接着通过 Sigmoid 激活函数，得到空间注意力权重矩阵 M_s 。

(4) 混合注意力机制

在混合注意力机制中，通道注意力和空间注意力可以通过串联、或者并联的方式进行组合。

2.3 基于深度学习的目标检测算法

基于深度学习的目标检测算法主要分为两大类：一类是基于候选区域的两阶段目标检测算法，另一类是基于回归的单阶段目标检测算法。在前者中，算法首先生成候选区域，然后再对这些候选区域中可能存在的目标进行分类和定位，代表性算法包括 R-CNN 系列等。而后者则可以通过深度卷积神经网络直接对目标物体进行定位和分类，在单一阶段内生成目标的类别概率和位置坐标，从而避免了前者生成候选区域的过程，代表算法包括 YOLO 系列和 SSD 系列等。

2.3.1 两阶段目标检测算法

二阶段目标检测算法，也称为基于感兴趣区域的目标检测方法，其核心思想是：首先从图像中生成候选区域，随后对这些候选区域进行目标分类和位置定位。这个过程分为两个独立的步骤，第一步是候选区域生成，第二步则包括目标分类和位置回归等进一步处理。代表性算法有 R-CNN、Faster R-CNN 等。

1. R-CNN

R-CNN 是利用深度学习进行目标检测的开山之作，在该算法出现之前，相关目标检测算法在标准 PASCAL VOC 数据集上的检测性能一直停滞不前。直到 Girshick 等人^[27]将卷积神经网络（CNN）引入到目标检测任务当中，并且提出经典的二阶段目标检测算法 R-CNN。该算法的提出标志着深度学习在目标检测领域的重大突破，其算法模型框架如图2.6所示，算法整体检测流程如下：

(1) 采用选择性搜索网络（Selective Search）对目标图像的颜色、纹理等相关重要特征进行搜索并分析，从中筛选出约 2 千个大小不一的候选区域。

(2) 对于上述筛选出的每个候选区域，先进行归一化操作，即将大小不一的候选区域转换为具有固定大小的标准形状，然后使用深度学习网络对其特征进行提取。

(3) 将上述提取到的特征送入每一类别的 SVM 分类器中，判断是否属于该类。

(4) 最后使用回归器精细修正每个候选框的位置。相较于传统以机器视觉为代表的目标检测算法，R-CNN 的主要改进点为以下三点：首先，在区域建议阶段，采用了选择性搜索算法，这一方法的出现有效地解决了传统目标检测算法中使用滑动窗口生成候选框时计算量过大的问题。其次，利用卷积神经网络对图像中的感兴趣区域进行特征提取，克服了传统目标检测方法中特征表达能力不足的问题。最后，在目标分类方面，算法结合了 SVM 分类器，并运用回归算法对目标边界进行补偿和修正，从而减


The image shows the RCNN model structure, which typically involves a convolutional neural network (CNN) for feature extraction, followed by region proposal networks (RPN) to generate candidate regions, and then a classification and regression stage for each region.

图 2.6 RCNN 模型结构

小感兴趣区域与实际目标之间的差异，提高了目标检测的准确性。R-CNN 算法的出现标志着目标检测进入了深度学习时代，相对于传统目标检测方法，R-CNN 在性能方面提升巨大，但是该算法在耗时，检测和训练速度上表现依旧欠佳，除此之外，训练所需要的存储空间巨大，以上种种因素也就导致了该算法难以在实际场景进行实际应用。为解决以上问题，后续研究者不断改进 R-CNN，推出了 SPPNet、FastR-CNN、FasterR-CNN 以及 MaskR-CNN 等二阶段目标检测算法。这些改进算法在速度和性能方面都有了显著提升，因此基于深度学习的目标检测方法也得以成功应用于工业领域。而以上在 R-CNN 系列中，FasterR-CNN 算法是其中最杰出的代表，也是目前最为经典的两阶段目标检测算法。

2. Faster R-CNN

FasterR-CNN 是截止目前 R-CNN 系列算法的最杰出的代表，也是二阶段目标检测算法中最为经典的物体检测算法，FasterR-CNN 算法的模型结构如图2.7所示。该算法使用了区域建议网络 (RegionProposalNetwork,RPN) 代替了原始的选择性搜索算法，以生成候选框。同时，将候选区域生成、特征提取、目标分类和位置回归等步骤进行了融合，进而实现了端到端结构的目标检测模型。算法的检测过程可分为以下步骤：首先，原始图像经过网络处理后生成特征图；其次，使用区域建议网络生成存在潜在目标的候选框，并将这些候选框映射到特征图上，生成相应的特征矩阵；最后，在 ROI 池化层中对每个特征矩阵进行缩放操作，随后通过一系列全连接层将其展平，最终得出检测结果。此外，在 FasterR-CNN 算法中还引入了锚框的概念。这些锚框位于滑动窗口的中心点，由多个具有不同尺寸和宽高比的边界框组成，用于检测同一位置可能存在的多个目标。通过区域建议网络 RPN 的处理，可以获得大约 300 个精确的候选区域。锚框的引入显著减少了模型生成候选框的数量，有效地减少了算法模型的计算复杂度。R-CNN 算法的优化方向在于将检测过程的各个步骤融合到主干卷积神经网络中，包括候选区域生成、目标分类以及位置回归，然后依赖 CNN 网络的强大性能和 GPU 加速来提升模型的训练和运行速度。继 FasterR-CNN 之后又产生了更多的 R-CNN 算法，比




图 2.7 Faster R-CNN 模型结构图

如 R-FCN^[28]、CascadeR-CNN^[29]以及 LibraR-CNN^[30]等。尽管二阶段目标检测算法在不断的迭代中提高了检测精度，但随着算法模型深度的增加，计算复杂度也随之上升，导致检测速度下降，难以满足实时检测的需求。

2.3.2 一阶段系列目标检测算法

两阶段目标检测算法包括两个关键步骤：首先生成感兴趣的候选区域，然后对这些候选区域进行分类和位置回归。然而，该算法可能会丢失目标区域的局部空间信息，从而对检测结果产生影响。另外，由于计算量较大，检测速度相对较慢，因此难以满足实际应用场景中的实时检测需求。为了解决这些问题，一阶段目标检测算法也因此应运而生。

1. YOLOv1

针对二阶段目标检测算法模型复杂度高、参数众多、训练时间长以及实时检测效果较差等问题。Redeem 等人提出了首个基于回归分析的目标检测算法 YOLO (you only look once)，该算法舍弃了选取候选框的建议，直接采用回归的方法对目标对象进行分类和位置定位，实现了经过单个阶段就可以直接获得最终的检测结果。该算法的核心理念在于将图像分割成多个网格，每个网格同时进行边界框的预测和类别概率的估算。在检测过程中，如果待检测目标的中心正好位于某个网格内，那么该网格将负责预测目标的位置和类别。这一优化简化了整体的网络结构，显著提高了检测速度，相较于二阶段目标检测算法 FasterR-CNN，性能提升了大约 10 倍。YOLO 算法的检测流程如下图所示：YOLO 将输入图片划分为 $S \times S$ 个格子 (Grid)，每个格子预测 B 个框，如果待检测目标的中心恰好位于某个网格之内，那么该网格将负责预测该目标的位置和类别。YOLO 输出为一个数学公式 $S \times S \times (B \times 5 + C)$ ，这里的 C 为预测可能的分类数量， B 为每个网格要预测的 boundingbox 的数量， $S \times S$ 是划分的网格数量，5 表示的是对于一个格子内的每个 boundingbox，都要预测 5 个值 $[x, y, w, h, c]$ ， (x, y) 表示框的中心点相




图 2.8 YOLO 流程检测图

对于这个格子的偏移, (w, h) 表示这个框在原图尺寸上的宽长, 这样得到预测值后先应用 (x, y) 找到框的中心点, 再通过 (w, h) 即可作出一个框, C 为置信度 confidence, 数学公式如 2.15 所示, 表示框内有物体的概率乘以这个框和真实目标框之间的 IoU (truth 表示真实框, pred 表示预测框), 也就是说, 如果这个框对应的是背景, 那么这个值应该是 0, 如果这个框对应的是前景, 那么这个值应该是与对应前景和真实目标框的 IoU。

$$\text{confidence} = \text{Pr}(\text{Object}) \times \text{IoU}_{\text{pred}}^{\text{truth}} (2 - 1) \quad (2.15)$$

2. YOLOv2

尽管 YOLOv1 在检测速度方面表现出色, 但在物体定位方面存在精度不足的问题, 召回率 (recall) 相对较低, 同时在检测精度上也不如 R-CNN 系列的方法。针对以上问题, YOLOv2 提出了几种改进策略来提升 YOLOv1 模型, 其具体改进点如图 2.9 所示。




图 2.9 YOLOv2 模型提升部分

上图总结了从 v1 到 v2 的各项改进, 其中主要的二点: 首先为了避免过拟合, YOLOv2

采用了 DarkNet19 作为特征提取网络，使用 BN (BatchNormalization) 层来替代 dropout 层，并添加在每个卷积层后面，这一改进显著提高了模型的收敛速度，同时减少了对其他正则化方法的依赖；其次，作者借鉴了 FasterR-CNN 的思想引入了 anchors，YOLOv1 在 BoundingBox 位置预测上表现并不好，因为它直接给出宽高，相比 FasterR-CNN 中有预设的 Anchors，网络只需要预测一个 offset，精准度更高。在 FasterR-CNN 系列的 Anchors 是人工指定的，但 YOLO 中的 Anchors 是通过 K-means 算法得到的，主要是因为使用 FasterR-CNN 的公式可能会导致预测框出现在图像的任意位置，容易给模型的训练带来不必要的开销，所以位置还是沿用 YOLOv1 中的相对于网格的预测方式，宽高则采用相同的指数形式。数学公式如 2.16 所示：

$$\begin{aligned} b_x &= \sigma(t_x) + C_x \\ b_y &= \sigma(t_y) + C_y \\ b_w &= p_w \times e^{t_w} \\ b_h &= p_h \times e^{t_h} \end{aligned} \quad (2.16)$$

其中， t_x, t_y, t_w, t_h 分别为预测框的中心点坐标及宽高尺寸， C_x 和 C_y 为负责预测该目标的网格坐标， p_w 和 p_h 分别为预测框对应 anchor 的宽高尺寸，这里将 t_x 和 t_y 做 sigmoid 处理是为了将预测框的中心点控制在当前网格内，从而避免预测框超过网格外。

3. YOLOv3

作为 YOLO 系列的经典之作，YOLOv3 的检测性能获得了显著提升。其主要的提升点在于。第一，用了名为 Darknet-53 的深度卷积神经网络作为特征提取器。相较于 YOLOv2 中所使用的 DarkNet19，新的网络使用了更多的卷积-53 层卷积，同时，添加了残差网络中的残差连结结构，以提升网络的性能。从图??可以看出，在 ImageNet 数据集上，虽然 DarkNet53 的 top1 准确率和 top5 准确率几乎与 ResNet101 和 ResNet152 持平，但速度却显著高于后两者。因此，相较于所对比的两个残差网络，DarkNet53 在速度和精度上具有更高的性价比。




图 2.10 Darknet 与其他网络结构对比

另一方面优化了对边界框的预测、借鉴特征金字塔网络 (Featurepyramidnetworks,

FPN) 思想,采用多尺度的特征融合进行目标检测。FPN 的创新点在于提出了一种自底向上的结构,融合不同制度的特征图去进行目标检测。主要是因为网络浅层的特征图包含更多的细节信息,但语义信息较少,而深层的特征图则恰恰相反,所以,对于 YOLO 的前代系列。对于小目标的检测, YOLOv3 的检测效果好很多。FPN 的核心思想如下,随着网络深度的加深,降采样操作的增多,图像细节信息不断被破坏,从而导致对小物体的检测效果逐渐变差,而大目标由于像素较多,仅靠网络的前几层还不足以使得网络能够认识到大物体(感受野不充分),但随着层数变多,网络的感受野逐渐增大,网络对大目标的认识越来越充分,检测效果自然会更好。于是,一个很简单的解决方案便应运而生:浅层网络负责检测较小的目标,深层网络负责检测较大的目标,即多层检测(multi-level detection),不同尺度的物体由不同的特征图去做预测。如图2.11所示,底层黄色部分代表输入的原始图片,可以看到,三个尺度的网络分别用于检测不同大小的目标,他们会产生各自的目标预测框和对应的类别的类别概率。




图 2.11 FPN 网络结构

4. YOLOv4 v7

YOLOv3 作为 YOLO 系列经典的版本,现在的众多目标检测算法也都是基于该版本进行迭代优化。同样 YOLOv4 在算法架构、特征融合和优化方面也做出了显著创新。它引入了 CSPDarknet53 作为主干网络,融合了路径聚合网络 PANet 和空间注意力机制 SAM 等特征融合模块,以处理多尺度特征,进而取得了显著提升。YOLOv5 的网络结构延续了 YOLO 系列的设计,主要由输入端(Input)、主干网络(Backbone)、多尺度特征融合网络(Neck)和预测分类器(Head)四个部分组成。其中输入端采用 Mosaic 数据增强以加快模型的收敛速度;主干网络主要由 CBS(Conv+BatchNorm+SiLU)+C3+SPPF 组成;多尺度特征融合网络 Neck 通过 FPN 结构自顶向下上采样和 PAN 结构自底向上下采样进行多尺度特征融合,这不仅增加了不同尺寸特征图的语义信息和特征信息,还弥补了经过特征金字塔后丢失的目标信息。另外在 YOLOv5 中还引入了不同的版本的概念,分别为 YOLOv5s、YOLOv5m、YOLOv5l、YOLOv5x 和 YOLOv5n 五个版本,它们各自适用于不同的设备和需求。YOLOv5s 适用于资源有限的设备,速度最快但准

精度较低；YOLOv5m 提供速度和精度的平衡；YOLOv5l 具有高精度但速度较慢；YOLOv5x 提供最高精度但速度最慢；而 YOLOv5n 专为 Nano 设备优化，保持速度并提供适用于边缘设备的精度。这就需要开发者在选择模型时需考虑设备性能和任务精度需求。在 YOLOv7 版本中引入了可扩展的高效层聚合网络 E-ELAN、创新的过渡模块以及重参数化结构等策略，从而显著增强了语义信息表达和特征提取的能力，进一步提升了目标检测效果。

5.YOLOv8

YOLOv8 框架目前支持图像分类、物体检测以及实例分割任务，它最显著改进之处在于其出色的可扩展性。设计者将其打造成一个兼容 YOLO 历史版本的框架，使开发者可以自由切换并进行实验对比。此外，该框架引入了新的功能和改进，进一步提升了模型的性能和灵活性。这些创新包括全新的骨干网络、Anchor-Free 检测头和损失函数等。图2.12展示了 YOLOv8 的网络结构图，下面对 YOLOv8 的各个组成部分进行简单的阐述。主干网 Backbone 由 CBS 模块、C2f 模块和 SPPF 模块组成，即沿用了 YOLOv5 中的 CSP 的思想，其主要改动点将 C3 模块替换成了 C2f 模块，C2f 结构可以增强卷积神经网络的特征融合能力，提高推理速度，实现了进一步的轻量化；Neck 部分参考了 YOLOv7 的 ELAN 结构设计思想，将 YOLOv5 中的 C3 模块替换成了梯度流更丰富的 C2f 结构；Head 部分相比 YOLOv5 改动较大，换成了目前主流的解耦头结构，将分类和检测头分离；同时 YOLOv8 改变了以往的 Anchor-Base，使用了 Anchor-Free 的思想，这一创新使模型更具自适应性，能够更准确地预测目标的位置和尺寸，减少了对先验信息的依赖，进而提高了目标检测的鲁棒性。并且，为了满足不同场景的需求，在 YOLOv8 中也引入了 YOLOv5 不同版本的概念，主要分为 YOLOv8n、YOLOv8s、YOLOv8m、YOLOv8l 和 YOLOv8x。同样，YOLOv8s 也适用于资源有限的设备，速度最快但精度较低。总体而言，YOLOv8 的设计主要汲取了 YOLO 历史版本以及其他基于 YOLO 的改进模型算法的相关设计，更加偏向于工程实践。

尽管 YOLOv8 在常见目标检测算法中具有一定优势，但其主要特征提取网络和颈部网络的参数量庞大，计算复杂度高，网络结构复杂，不适用于资源受限的移动设备平台。

综上所述，一阶段目标检测算法省略了候选区域生成步骤的过程，并且将特征提取、目标分类和位置回归整合到单一阶段进行操作。这种集成的方法极大地提高了检测速度，并且在处理小目标和密集目标时表现也依旧出色。一阶段算法的另一个优点是其端到端的训练方式，它可以更好地适应各种复杂场景和目标类别，使得模型更具通用性。这些特性使得一阶段目标检测算法在计算机视觉中具有广泛的应用，尤其在需要快速且准确的目标检测任务中表现出色。



图 2.12 yolov8 整体框架图

2.4 轻量级模型介绍

MobileNet 系列是 Google 团队针对移动端和嵌入式设备设计的高效轻量级卷积神经网络，其核心思想是通过优化网络结构与计算方式，在保证模型精度的同时大幅降低参数量与计算成本。从 MobileNetV1 到 V3 的迭代体现了轻量级模型在架构设计、自动化搜索与硬件适配等方面的持续突破。

1. MobileNetV1

作为该系列的开创性工作，MobileNetV1 提出了深度可分离卷积（Depthwise Separable Convolution），将传统卷积分解为两步：

- (1) 深度卷积（Depthwise Convolution），对每个输入通道单独进行 3×3 空间卷积；
- (2) 逐点卷积（Pointwise Convolution），通过 1×1 卷积融合通道信息。这种分解方式将标准卷积的计算复杂度从 $O(D_K^2 \cdot C_{in} \cdot C_{out})$ 降至 $O(D_K^2 \cdot C_{in} + C_{in} \cdot C_{out})$ ，其中 D_K 为卷积核尺寸， C_{in} 和 C_{out} 为输入/输出通道数。

此外，MobileNetV1 引入宽度乘数（Width Multiplier）和分辨率乘数（Resolution Multiplier），允许用户通过调节通道数与输入分辨率进一步压缩模型。实验表明，MobileNetV1 在 ImageNet 数据集上以 4.2M 参数达到 70.6% 的 Top-1 精度，计算量仅为 569M FLOPs（ 224×224 输入），显著优于同期轻量模型如 SqueezeNet。但 V1 的缺陷在于深层网络训练中梯度消失问题显著，并且通道维度压缩导致高阶语义信息丢失。

2. MobileNetV2

针对 V1 中深度卷积特征提取能力不足与激活函数信息丢失的问题，MobileNetV2 提出了倒残差结构（Inverted Residuals）与线性瓶颈（Linear Bottleneck）。倒残差结构在残差块中采用“扩展-压缩”策略：先通过 1×1 卷积升维（扩展层），再执行深度卷积，最后用 1×1 卷积降维（压缩层），确保低维空间的特征完整性。线性瓶颈层则移除了压缩层后的非线性激活（如 ReLU6），避免低维特征因 ReLU 的截断特性导致信息损失。网络结构上，V2 包含 17 个逆残差模块，总层数扩展至 54 层。

3. MobileNetV3

该版本结合神经架构搜索（NAS）与手工设计优化，进一步平衡精度与效率。其创新点包括：1) 基于资源约束的 NAS 技术，自动生成高效网络结构；2) 引入 h-swish 激活函数，在保留 swish 函数平滑特性的同时避免高计算成本；3) 设计轻量化注意力机制（SE 模块），精简通道注意力模块的计算量；4) 优化网络头部结构，减少冗余卷积层。

网络架构层面，V3 分为 Large 与 Small 两个版本。以 V3-Large 为例，采用 15 个 Bneck 模块，首层卷积核扩展至 16 通道，尾部引入 SE 模块增强特征选择性。在 ImageNet 上，V3-Large 实现 75.2% Top-1 精度（参数量 5.4M），推理速度较 V2 提升 15% 此外，MobileNetV3 首次提出硬件感知网络优化，通过分析设备实际推理速度调整网络结构，显著提升部署效率。

2.5 本章小结

第三章 数据集构建以及基准模型选取

3.1 引言

在中医药现代化进程中，实现中药饮片的自动识别对于提升中医药领域科研水平有着举足轻重的作用。然而，目前由于缺乏大规模、高质量的中药饮片标准图像数据集，严重制约了相关研究的深入推进。针对这一挑战，本章节聚焦于构建一个涵盖 40 种常见中药饮片类型的图像数据集，旨在为中药饮片图像识别技术的深入研究提供坚实可靠的数据支撑。

本章节将系统阐述中药饮片图像数据集的构建方法与技术路线，从数据采集入手，逐渐深入到图像预处理环节，通过各种数据增强策略扩充数据规模，最终完成数据集的合理划分。这些系统性工作的完成，不仅为中药饮片图像识别技术提供了高质量的数据支撑，更为构建基于深度学习的中药饮片快速辨识系统迈出了关键一步。



img/数据集构建流程图.png

图 3.1 数据集构建流程图

3.2 中药饮片图像采集

为测试训练好的中药饮片检测模型在实际场景中的表现，本研究采取两种不同渠道的收取中药饮片的图像数据。一方面通过淘宝平台购买药材样本，挑选 3 家评分在 4.9 以上的正规网店，采购了 40 种常见的中药饮片；另一方面在线下药店实地取样，保证中药饮片图像数据的多样性。所有样品都对照《中国药典》检查过确保是真品。

拍摄时使用红米 note12pro 手机，对于 40 种中药饮片分两种方式拍摄采集图像并分类命名，第一种方式是对于线上购买的中药饮片，为了提高模型泛化能力，选取多个外形、大小、颜色接近的不同类型的中药饮片，在 6 种不同的背景下精确拍摄照片图像；第二种方式是对于需要在药店实地取样的中药饮片，为了不影响药店经营以及提高图像采集效率，采用视频拍摄方式，后续从视频里截图获取高清图像。将模糊、重复以及饮片堆叠等不可用的图像去除后，最终初步建立了一个包含 4100 张中药饮片图像的数据集，并命名为 TCMDP40 (Traditional Chinese Medicine Decoction Pieces)。40 种中药饮片类别如表 3.1 所示。数据集 TCMDP40 部分不同背景下的图像如图 3.2 所示。

表 3.1 TCMDP40 数据集类别

桑枝	鸡血藤	鹿角	姜半夏	首乌藤	青皮	杜仲	白芷
使君子	川木槿	苍耳子	黄柏	赤芍	葛根	白茅根	钩藤
益母草	青蒿	荆芥	桂枝	槟榔	泽泻	狗脊	灵芝
土茯苓	苏木	茯苓	紫石英	石决明	阴起石	海螵蛸	大血藤
青风藤	白术	乳香	女贞子	干姜	芦根	厚朴	合欢皮



图 3.2 部分中药饮片图像

3.3 数据增强

数据增强 (Data Augmentation) 又称为数据扩增, 通过一系列数据变换操作来生成新的训练样本, 从而扩增数据集的规模和多样性, 其目的是使得数据集满足模型训练的要求。在中药饮片图像识别研究中, 高质量且多样化的数据集是训练出高性能检测模型的关键。然而, 本研究初步构建的 TCMDP40 数据集只有 4100 张图片, 这可能使模型学不到足够的特征, 为进一步提升模型的泛化能力和鲁棒性, 本研究将采用随机增强 (Random Augmentation)、混合增强 (Mixup Augmentation) 和马赛克增强 (Mosaic Augmentation) 三种数据增强方式对 TCMDP40 数据集进行扩充。

3.3.1 Random 随机增强

3.3.2 Mixup 数据增强

Mixup 是一种非常规的数据增强方法, 以线性插值的方式来构建新的训练样本和标签, 其核心思想就是随机将两张图像按一定的比例线性融合, 同时合并两者的边界框, 使得模型学习到不同图像之间得特征关系, 减少模型对单一样本得过拟合风险, 提

高模型的泛化能力。Mixup 方法的数学公式如 (3.1) 式、(3.2) 式所示。

$$\tilde{x} = \lambda x_i + (1 - \lambda)x_j \quad (3.1)$$

$$\tilde{y} = \lambda y_i + (1 - \lambda)y_j \quad (3.2)$$

其中, x 是输入向量, y 是标签的 one-hot 编码, λ 取值范围是 0 到 1 且服从参数为 α 的 Beta 分布。通过将不同样本的数据和标签 (x_i, y_i) 、 (x_j, y_j) 进行线性混合来生成新的样本 $(\tilde{x}, \tilde{y})$, 以提高深度神经网络的泛化能力和对抗样本的抵抗力。Mixup 数据增强效果如图3.3所示。




图 3.3 Mixup 数据增强效果图

3.3.3 Mosaic 数据增强

Mosaic 数据增强技术的核心在于从初始数据集中随机选取四幅图片, 并在经过适当的缩放处理后, 按照左上、左下、右上、右下的顺序进行拼接, 从而形成一幅与原图

尺寸相同的新图像。由于涵盖四种不同的图片，新图像不仅拥有更为丰富的背景信息，而且在进行模型训练时，能够大幅提高传递的批样本总量 (Batch Size)。因此，Mosaic 增强不仅能增强模型鲁棒性，让模型学习到超出常规语义信息的目标特征，还能加强模型批归一化层 (Batch Normalization) 的效果。Mosaic 数据增强效果如图3.4所示。




图 3.4 Mosaic 数据增强效果图

3.4 数据集标注及划分

原始中药数据集中

3.5 本章小结

第四章 基于改进 YOLOv8 的中药饮片检测模型

4.1 引言

深度学习技术在众多视觉任务中已经展示出了卓越的表现，其中包括图像分类与目标检测等常见图像识别任务。但是，对于中药饮片图像检测任务中的目标尺寸差异大、形态纹理多样性显著（如切片形变、堆叠遮挡）、背景复杂及类别分布不均衡等挑战，传统的神经网络常因特征提取能力不足或计算冗余导致漏检与误检，在识别精度和泛化能力方面遭遇困境。YOLOv8 作为 YOLO（You Only Look Once）系列的高性能模型，它通过引入跨阶段特征融合 C2f 模块重构特征提取网络，采用任务对齐分配策略 TSA(Task-Aligned Assigner) 优化正负样本分配策略，并构建更高效的解耦头结构实现分类与定位任务解耦，在小目标检测精度和模型推理速度方面具有显著优势。因此，本章针对中药饮片检测的特殊需求，选取 YOLOv8 作为基准模型，从特征提取、上下文建模及损失优化三方面改进，接下来将详细阐述各模块的设计动机、实现方法及其对检测性能的提升作用。

4.2 基于改进多维度动态卷积的特征提取

在中药饮片检测的场景中，目标尺度差异显著，例如完整的白芪切片尺寸可达 100×100 像素，而风藤碎屑的破碎残片可能仅占 10×10 像素。然而 YOLOv8 骨干网络中的 C2f 模块是由传统静态卷积构成的，静态卷积核的大小固定且感受野相对较小，这导致它们在中药饮片检测中难以自动适应饮片尺寸大小，从而限制了它们捕捉多样化局部信息的能力，在提取饮片的复杂纹理特征方面存在一定的局限性。针对这一问题，本章提出将全维度动态卷积（Omni-dimensional Dynamic Convolution, ODConv）模块集成至 YOLOv8 的骨干网络（CSPDarknet）中，通过并行策略利用多维注意力机制来动态调整卷积核在空间、输入输出通道以及卷积核数目等维度的权重分配，初步增强网络对饮片关键特征的捕捉能力。全维度动态卷积 ODConv 将四类注意力权重通过逐元素相乘融合至卷积核，它的核心公式如下：

$$Y = \sum_{i=1}^n (\alpha_{wi} \cdot \alpha_{fi} \cdot \alpha_{ci} \cdot \alpha_{si} \cdot W_i) * X \quad (4.1)$$

其中, $Y \in \mathbb{R}^{h \times w \times c_{out}}$ 表示输出通道数为 c_{out} , 大小为 $h \times w$ 的输出特征, $X \in \mathbb{R}^{h \times w \times c_{in}}$ 表示输入通道数为 c_{in} , 大小为 $h \times w$ 的输入特征, α_{si} 表示空间维度的注意力标量, 对输入特征图进行全局平均池化操作, 生成与卷积核空间尺寸相对应的注意力权重矩阵,

另外这一机制还可动态调整卷积核在不同空间位置的响应强度，比如增强饮片边缘区域的卷积核权重。 α_{ci} 表示输入通道维度的注意力标量，它通过全连接层对输入通道进行重要性评分，并且能够抑制冗余通道噪声，突出与饮片材质相关的特征通道。 α_{fi} 则表示沿输出通道的注意力标量，能够动态分配输出通道的权重，提升关键特征图的信息密度， α_{wi} 是卷积核 W_i 的注意力标量，组合多个卷积核，根据输入特征自适应地调整各个卷积核的权重。

全维度动态卷积结构图如图4.1所示。输入特征 X 经过全局平均池化 (GAP) 压缩为 c_{in} 个特征向量，经过全连接层 (FC) 将特征向量映射到低维空间，再经过 ReLU 激活函数将特征向量中的负值置为零，最后将其输出到并行的四个分支，前三个分支经过全连接层和 Sigmoid 激活函数后分别得到卷积核空间核尺寸、输入通道数、输出通道数上的注意力标量，最后一个分支经过全连接层和 Softmax 激活函数后得到卷积核数量维度上的注意力标量，将得到的四个维度上的注意力标量与卷积核相乘累加，与输入特征 X 卷积得到输出特征 Y 。




图 4.1 全维度动态卷积（待修改成横向的结构）

YOLOv8 的骨干网络由许多 C2f(Cross Stage Partial Fusion Bottleneck with 2 Convolutions) 模块构成，c2f 模块中的每个 Bottleneck 模块都由标准卷积与跨阶段残差连接组成。本文将原来 Bottleneck 模块中的第二个 3×3 卷积层替换为全维度动态卷积层，形成改进后的 Bottleneck_OD 模块。然后将它替换原本的 C2f 模块中的标准 Bottleneck 模块，从而构建出具有动态特征学习能力的 C2f_OD 复合模块。最终将 C2f_OD 应用到 YOLOv8 网络架构的 Backbone 层当中原本四个 c2f 模块，改进后的结构如图4.2、4.2所示。

同之前相比，改进后的 C2f_ODConv 模块实现了四维动态卷积核的自适应调整，使得模型能够针对中药饮片图像中不同形态的饮片特征进行动态特征提取，能够有效提




图 4.2 改进 c2f (待修改))




图 4.3 改进 yolov8 架构 (待修改))

升网络对饮片表面纹理特征、破损边缘的判别能力，为中药饮片检测提供了可靠的技术方案。

4.3 基于卷积和注意力融合 CAFM 的改进

YOLOv8 的 Neck 网络通过构建 PAN-FPN 结构实现自顶向下和自底向上的多尺度特征融合，将深层语义信息与浅层细节特征结合后传递给检测头。但是，在中药饮片检测任务中，Neck 网络在某种意义上只靠卷积操作进行特征融合，它的局部感受野有时不能捕捉饮片与复杂背景之间的全局关联关系，而检测头依赖 Neck 提供的局部特征，也难以鉴别饮片间的分离边界，全如图4.4所示，对于复杂背景和堆叠饮品的检测精度不够。为了缓解上述问题，本文将卷积和注意力融合模块 CAFM(Convolution and Attention Fusion Module) 模块嵌入 Yolov8n 的 neck 网络中。CAFM 模块的两大核心结构

img/网络结构图、模块图/后续补复杂背景影响识别的图.jpg

图 4.4 后续补复杂背景影响识别的图

是局部分支 (Local Branch) 和全局分支 (Global Branch), 局部分支则通过卷积和通道重排来实现局部特征信息的提取, 全局分支使用注意力机制来建模长距离特征依赖关系, 从而更好的理解与捕获全局信息, 最后通过残差连接融合两者的特征输出。CAFM 的整体结构如4.5所示。相较于普通注意力机制的只关注局部或者只关注整体的结构, CAFM 通过这种“双分支合作”的结构, 能够把中药饮片的局部纹理细节和全局轮廓信息结合起来, 让模型检测更精确。在局部分支设计中, 为增强跨通道信息交互能力

img/网络结构图、模块图/CAFM 结构图.jpg

图 4.5 CAFM 结构图 (待修改)

并优化信息整合效率, 首先使用 1×1 卷积来调整通道数, 随后进行通道混洗操作, 将输入特征沿通道轴划分为 G 个互斥子组, 在各子组内采用深度可分离卷积进行特征重组, 然后每个组得到的输出张量沿着通道维度连接得以生成新的输出张量, 最终通过 $3 \times 3 \times 3$ 卷积来提取细节特征, 整个过程可以用公式表示为:

$$F_c = W_{3 \times 3 \times 3}(CS(W_{1 \times 1}(X))) \quad (4.2)$$

其中 F_c 表示全局分支的输出特征, $W_{1 \times 1}$ 是 1×1 二维卷积操作, $W_{3 \times 3 \times 3}$ 是包含宽度高度和通道数的三维卷积, CS 是通道混洗操作, X 则是输入特征向量。

在全局分支中, 首先通过 1×1 卷积和 3×3 深度卷积生成查询 (Q)、键 (K)、值 (V), 产生 3 个形状为 $B \times H \times W \times C$ 的张量, 其中 B, H, W, C 分别为样本数、特征

图高度、特征图宽度和通道数。为了计算注意力图 (Attention Map)，需将 Q, K, V 的空间维度展平，利用 Softmax 函数将其重塑为 $B \times N \times C$ 的形状，其中 $N=H \times W$ ，重塑后的 Q, K 和 V 分别为 $\hat{Q}, \hat{K}, \hat{V}$ ，通过 $\hat{Q}, \hat{K}$ 计算注意力图，减少了计算负担。全局分支可以表示为：

$$F_{\text{att}} = W_{1 \times 1} \text{Attention}(\hat{Q}, \hat{K}, \hat{V}) + Y \quad (4.3)$$

$$\text{Attention}(\hat{Q}, \hat{K}, \hat{V}) = \hat{V} \text{Softmax}(\hat{Q} \hat{K} / \alpha) \quad (4.4)$$

其中， F_{att} 为全局分支的输出， $\text{Attention}(\hat{Q}, \hat{K}, \hat{V})$ 为加权后的输出特征图， $\hat{V}$ 为加权值， α 为可学习的缩放参数。CAFM 的计算结果为：

$$F_{\text{out}} = F_{\text{att}} + F_{\text{conv}} \quad (4.5)$$

实验证明，在 YOLOv8 的初始上采样层处引入 CAFM 模块，能够增强全局注意力，强化局部细节特征提取，并且更好地进行动态特征融合，这有效解决了原始架构在中药饮片检测中的长距离依赖缺失、多尺度适应性不足等问题，显著提升了检测精度与鲁棒性。

4.4 基于 NWD 的标签分配与损失函数改进

YOLOv8 的损失函数设计精巧，包含三大部分：边界框损失、分类损失和分布焦点损失 (Distribution Focal Loss，简称 DFL)，三者共同协作，确保模型在定位目标和分类目标时达到最优性能。

边界框损失是 YOLOv8 中用于衡量预测边界框与真实边界框匹配程度的指标。YOLOv8 采用了 Complete IoU (CIoU) 损失，这一损失函数在传统 IoU 的基础上进行了改进，不仅考虑了重叠面积，还引入了中心点距离和宽高比的惩罚项。其数学公式如下：

$$\mathcal{L}_{CIoU} = 1 - IoU + \frac{\rho^2(\mathbf{b}, \mathbf{b}^{gt})}{c^2} + \alpha v \quad (4.6)$$

其中，IoU 表示预测框 $\mathbf{b}^{gt}$ 与真实框 $\mathbf{b}^{gt}$ 的交并比，即重叠面积除以并集面积的比值， $\rho(\mathbf{b}, \mathbf{b}^{gt})$ 是预测框中心与真实框中心的欧氏距离， c 是包含预测框和真实框的最小外接矩形的对角线长度， v 衡量宽高比的一致性，用于惩罚形状差异， α 是平衡参数，增强宽高比惩罚的权重。CIoU 损失通过综合考虑位置和形状信息，使得边界框回归更加精确，在目标密集或大小变化较大的场景中表现出色。

分类损失函数通常用于优化模型对目标类别的预测。YOLOv8 采用的分类损失是二元交叉熵 (Binary Cross Entropy, BCE) 损失，其公式为：

$$\mathcal{L}_{cls} = -\frac{1}{N} \sum_i [y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i)] \quad (4.7)$$

其中, y_i 是真实标签 (1 表示正样本, 0 表示负样本), $\hat{y}_i$ 是模型预测的概率, N 是样本总数, BCE 通过最小化预测概率与真实标签之间的差异, 确保模型能够准确区分目标类别。分布焦点损失是 YOLOv8 中一项创新设计, 用于进一步优化边界框坐标的回归。不同于传统的直接回归坐标值, DFL 将边界框的坐标建模为一个分布, 并通过焦点机制增强对靠近真实坐标的预测值的关注。其计算过程较为复杂, 涉及对坐标偏移量的概率分布建模, 最终通过交叉熵优化分布参数。

尽管 CIoU 损失在 YOLOv8 中表现优异, 但其核心指标 IoU 在某些场景下仍然存在局限性, 尤其是在中药饮片这样的小目标检测任务中。这些局限性主要体现在一方面 IoU 对位置偏差极为敏感。对于小目标 (例如尺寸仅为几像素到十几像素的对象), 即使预测框与真实框仅偏移几个像素, IoU 值也会急剧下降。例如, 一个 6×6 像素的目标框偏移 2 像素, 其 IoU 可能从 0.5 降至接近 0。这种敏感性会导致标签分配的不稳定性, 使得许多本应为正样本的预测框被错误标记为负样本, 影响模型的训练效果。另一方面, IoU 难以有效处理轮廓边缘形状复杂的对象。中药饮片的形状往往不规则, 可能呈现出参差不齐的边缘或非矩形轮廓。传统的 IoU 基于矩形框的重叠计算, 无法准确反映这类目标的真实重合程度, 尤其在目标密集或相互重叠时, IoU 的表现更加不理想。

为了克服 CIoU 在中药饮片检测中的局限性, 本文引入归一化 Wasserstein 距离 (Normalized Gaussian Wasserstein Distance) 作为部分替代指标, 并且利用权重参数来对 CIoU 和 NWD 度量值的贡献比例进行控制, 对两者进行加权平均, 从而获得改进的损失函数, 将其命名为 NWD_CIoU, 这样既能够对两个边界框之间的相似度进行更加全面地评估, 同时也能够降低优化难度。NWD_CIoU 损失函数在保有原来特性的同时, 将每个边界框建模为一个二维高斯分布, 并使用 Wasserstein 距离计算两个高斯分布的相似度, 这个相似度可以用来衡量预测边界框与真实边界框的相似度, 从而判断目标匹配度。所以, 即使预测框与真实框无重叠, NWD_CIoU 也特别适用于检测细微的中药饮片。

NWD_CIoU 的计算过程分为以下步骤:

1. 高斯建模: 将每个边界框 $R = (c_x, c_y, w, h)$ (中心坐标为 c_x, c_y , 宽为 w , 高为 h) 表示为二维高斯分布:

$$\mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma}), \quad \boldsymbol{\mu} = [c_x, c_y]^\top, \quad \boldsymbol{\Sigma} = \begin{bmatrix} \frac{w^2}{4} & 0 \\ 0 & \frac{h^2}{4} \end{bmatrix} \quad (4.8)$$

其中，方差矩阵 σ 基于边界框的宽高，反映了分布的尺度特性。

2. 计算 Wasserstein 距离：计算真实框 $\mathcal{N}_a$ 和预测框 $\mathcal{N}_b$ 的两个高斯分布之间的二阶 Wasserstein 距离，公式如下：

$$W_2^2(\mathcal{N}_a, \mathcal{N}_b) = \left\| \left[c_{x_a}, c_{y_a}, \frac{w_a}{2}, \frac{h_a}{2} \right]^\top - \left[c_{x_b}, c_{y_b}, \frac{w_b}{2}, \frac{h_b}{2} \right]^\top \right\|_2^2 \quad (4.9)$$

该距离综合考虑了中心位置和尺度的差异。

3. 归一化 NWD：将 Wasserstein 距离归一化为 $[0,1]$ 范围内的值：

$$NWD(\mathcal{N}_a, \mathcal{N}_b) = \exp \left(-\frac{\sqrt{W_2^2(\mathcal{N}_a, \mathcal{N}_b)}}{C} \right) \quad (4.10)$$

其中， C 是一个与数据集相关的归一化常数，通常取数据集目标的平均尺寸。

4. 构建 NWD_CIoU 损失函数：本研究提出渐进式混合度量策略，构建动态权重函数 $\lambda(t)$ ，通过它将 CIoU 与 NWD 耦合在一起，初始阶段以 CIoU 主导确保快速定位，后期逐步增强 NWD 权重强化细粒度对齐，从根本上消除传统 IoU 系列指标对目标绝对尺度的依赖性，实现真正的尺度不变性。

$$\lambda(t) = 0.5 \times (1 + \cos(\pi t/T)) \quad (4.11)$$

$$\mathcal{L}_{NWD_CIoU} = (1 - \lambda(t)) \times (1 - CIoU) + \lambda(t) \times (1 - NWD) \quad (4.12)$$

其中，其中 t 为当前训练轮次， T 为训练总轮次，

4.5 实验设计与结果分析

4.5.1 实验数据集

本实验所用的数据集是第三章提到的对 TCMDP40。

4.5.2 实验平台及参数设置

为了确保各个实验结果的公平性和可靠性，本文在实验的过程中都采取统一的超参数，实验的训练参数如下表4.1所示。另外，所有实验也采取完全一样的实验环境，实验环境如下表4.2所示。

表 4.1 实验训练参数

名称	图片大小	初始学习率	优化器	Batch-size	Epoch
参数设置	640×640	0.01	SGD	16	200

表 4.2 实验环境

名称	信息
CPU	Intel Xeon Gold 6248R
核心	24 核
显卡	Tesla V100S-PCIE-32GB (1)
内存	50G
操作系统	Ubuntu 20.2
Python	3.9.0
PyTorch	1.11.0
CUDA	11.3

4.5.3 评价指标

在目标检测算法中，常常用混淆矩阵（Confusion Matrix，CM）来直接观察各种预测类别存在的差错以及它们差错程度所占的比例。以本文的中药饮片检测模型识别白术举例，若图像中是白术，模型也预测为白术，可称为真正例（True positives，TP），这表示模型成功识别了白术。若图像中是黄芷，但模型预测为白术，则称为假正例（False Positive，FP），这是一种误报，模型把黄芷错认为白术。若图像中是白术，但模型预测为黄芷，可称为假负例（False Negative，FN），这是一种漏报，模型未能识别出白术。若图像中是黄芷，模型预测也为黄芷，则称为真负例（True Negative，TN），这表明模型能够正确区分黄芷和白术，在负类上的预测是准确的。

基于混淆矩阵，目标检测中常用来衡量算法检测性能的指标有召回率（Recall）、精确率（Precision）、平均精度（Average Precision，AP）和平均精度均值（mean Average Precision，mAP）

（1）精确率（Precision）精确率是衡量模型准确程度的指标，指的是预测正确的样本占全部预测结果的比例，计算方式如4.13所示：

$$Precision = \frac{TP}{TP + FP} \quad (4.13)$$

（2）召回率（Recall）召回率是衡量模型正确识别正类样本能力的指标，是指模型正确识别的样本在所有实际为正类样本中比例，计算方式如4.14所示：

$$Recall = \frac{TP}{TP + FN} \quad (4.14)$$

(3) 平均精度 (Average Precision, AP) 平均精度 AP 就是以召回率为横轴, 精确率为纵轴所得到的 Precision-recall 曲线的面积。所以实际上 AP 就是对 PR 曲线上的精确率求均值, 其计算方式如积分公式4.15所示:

$$AP = \int_0^1 P(R) dR \quad (4.15)$$

(4) 平均精度均值 (mean Average Precision, mAP) 平均精度均值 (mAP) 是对所有类的 AP 值的求平均值, 它提供了模型在所有类别上的整体性能评估。其数学公式如4.16所示:

$$mAP = \frac{1}{C} \sum_{c=1}^C AP_c \quad (4.16)$$

其中 C 是所有类别的数量, AP_c 是第 c 个类别的 AP。

4.5.4 消融实验

4.5.5 对比实验

4.6 本章小结

第五章 改进的轻量化中药饮片检测模型

5.1 引言

可以看到，第四章的改进 Yolov8 模型对中药饮片的检测性能有所提升，但是模型推理速度有所下降，并且从实验结果分析来看，虽然能够很好地识别鸡血藤、女贞子等切片状和颗粒状的饮片，但是对于类似钩藤的枝叶状饮片检测精度不够，所以，本章将针对这两个问题，一方面引入改进的蛇形卷积 (dynamic snake convolution, DSConv) 和渐进特征融合模块 (Asymptotic Feature Pyramid Network, AFPN) 来提升模型对于枝叶状中药饮片的准确度，另一方面通过引入改进的 MobileNetV3 网络来对初始 yolov8 进行模型轻量化。

5.2 基于多尺度特征融合的轻量级中药饮片检测模型改进

5.2.1 基于蛇形动态卷积 DSConv 的改进与替换

对于一些枝叶状的中药饮片，例如钩藤、白茅根、青蒿和苏木，由于它们的植物生理形态和炮制手法不同，常常呈现细管状、细丝状或蜷曲状，这些复杂形态和不规则结构对于卷积核固定的传统卷积方式来说难以适应，并且容易出现特征提取不连续的情况导致漏检。动态蛇形卷积 (Dynamic Snake Convolution, DSConv)^[31] 是一种针对管状结构特征提取设计的卷积方式，相对于可变形卷积缺乏对管状结构形态的针对性约束来说，它充分考虑了管状结构的拓扑几何约束，通过引入迭代策略和特殊的偏移量计算方式，使卷积核能够更好地贴合管状结构的形状，准确捕捉其局部特征。因此，对于本研究，引入 DSConv 能够在处理枝叶状的饮片图像时精准地捕捉细枝和蜷曲部分的特征，而传统卷积可能会遗漏这些细节。DSConv 的数学公式如下：

(1) 标准 2D 卷积坐标表示设标准 2D 卷积的卷积核位置集合为 K ，卷积核中心坐标为 (x, y) ，扩张率为 1 的 3×3 卷积核 K 可以表示为：

$$K = \{(x-1, y-1), (x-1, y), (x-1, y+1), (x, y-1), (x, y), (x, y+1), (x+1, y-1), (x+1, y), (x+1, y+1)\} \quad (5.1)$$

(2) 引入变形偏移量后的位置迭代计算偏移量预测模块是 DSConv 的关键组成部分，它通过卷积层对输入特征图进行特征提取，学习到目标的几何信息，并根据这些信息预测出每个采样点的偏移量。这些偏移量反映了目标的形状和位置变化，为卷积核的自

适应调整提供依据。x 轴方向上卷积核位置的计算公式为：

$$K_{i\pm c} = \begin{cases} (x_{i+c}, y_{i+c}) = (x_i + c, y_i + \sum_{k=i}^{i+c} \Delta y_k) \\ (x_{i-c}, y_{i-c}) = (x_i - c, y_i + \sum_{k=i-c}^i \Delta y_k) \end{cases} \quad (5.2)$$

其中，i 表示当前位置索引，c 表示距离中心位置的偏移量， Δy_k 表示在 y 方向上的偏移量。

y 轴方向上卷积核位置的计算公式为：

$$K_{j\pm c} = \begin{cases} (x_{j+c}, y_{j+c}) = (x_j + \sum_{k=j}^{j+c} \Delta x_k, y_j + c) \\ (x_{j-c}, y_{j-c}) = (x_j + \sum_{k=j-c}^j \Delta x_k, y_j - c) \end{cases} \quad (5.3)$$

其中，j 表示当前位置索引，c 表示距离中心位置的偏移量， Δx_k 表示在 x 方向上的偏移量。位置计算模块根据偏移量预测模块输出的偏移量，按照迭代策略计算卷积核每个网格的位置。在计算过程中，充分考虑管状结构的形态特点，确保卷积核能够沿着管状结构的走向进行采样，从而提高对管状结构特征的捕捉能力。

(3) 双线性插值公式由于偏移量 Δ 通常是分数，需要使用双线性插值来计算非整数位置的特征值。设非整数位置为 $K = (x, y)$ ，其周围四个整数位置分别为 $K_1 = (x_1, y_1), K_2 = (x_1, y_2), K_3 = (x_2, y_1), K_4 = (x_2, y_2)$ ，则双线性插值公式为：

$$f(x, y) = (1-u)(1-v)f(x_1, y_1) + (1-u)v f(x_1, y_2) + u(1-v)f(x_2, y_1) + uv f(x_2, y_2) \quad (5.4)$$

其中， $u = x - x_1, v = y - y_1, f(x, y)$ 表示非整数位置 (x, y) 的特征值， $f(x_1, y_1), f(x_1, y_2), f(x_2, y_1), f(x_2, y_2)$ 分别表示周围四个整数位置的特征值。

(4) 卷积操作公式经过双线性插值得到每个采样点的特征值后，卷积操作的计算公式为：

$$y(p_0) = \sum_{p_n \in K} w(p_n) \cdot x(p_0 + p_n + \Delta p_n) \quad (5.5)$$

其中， p_0 是输出特征图上的位置， K 是经过偏移调整后的卷积核位置集合， $w(p_n)$ 是卷积核在位置 p_n 的权重， $x(p_0 + p_n + \Delta p_n)$ 是经过双线性插值得到的特征值。

基于 DSConv 本研究提出一种双分支动态蛇形卷积方式来替换 C2f 模块的 Bottle-Neck 层中的卷积层，并将其命名为 D2SC2f 模块。

5.2.2 引入渐进特征金字塔网络 AFPN 进行多尺度特征融合

传统特征金字塔网络 (FPN) 在一定程度上能够整合不同尺度的特征，但其融合方式存在局限性。通常非相邻层次特征之间的语义差异显著大于相邻层次，尤其是底层和顶层特征，甚至存在互相矛盾的信息，若是简单地通过直接上采样或者下采样相融，

可能会造成信息损失和分辨率不足，从而影响检测效果。

针对上述问题，本章引入渐进特征金字塔网络 (Asymptotic Feature Pyramid Network, AFPN)^[32]对 yolov8 的 neck 层进行改进。AFPN 采用了一种渐进式架构设计进行逐步特征融合，其网络结构如下图所示：具体来说就是在特征提取的骨干网络中采用一种由下而上分级的策略，通过自适应学习重要性权重来有序地融合特征。起初先结合底层的细节特征，然后逐渐向上引入更深层次的特征，最终融合最高层的抽象特征。这种渐进融合的方式能够逐步地减少非相邻层之间的语义差距，以从低到高相邻的特征 P2、P3、P4 为例，网络先融合 P2 和 P3 的特征，可以减少二者之间的语义差异，然后整体继续融合 P4，由于 P3 和 P4 相邻，也使得 P2 和 P4 的差异缩小。

(便于编辑，后续补多层次融合图)

在特征融合前，AFPN 要确保不同层级之间的特征维度保持一致。具体而言，针对上采样过程，网络采用 1×1 卷积压缩通道维度，并结合双线性插值实现分辨率提升；对于下采样操作，则通过动态配置卷积核参数适配不同缩放需求：2 倍下采样选用 2×2 卷积核（步长 2），4 倍和 8 倍下采样分别采用 4×4 （步长 4）与 8×8 （步长 8）的核结构。此类策略在减少维度差异的同时，有效保留了跨层级特征的语义连贯性，从而为后续融合提供高兼容性的输入。

为此，AFPN 借助自适应空间融合 (ASFF) 技术，为不同层次的特征分配空间权重。如图所示以融合三个层次的特征为例，设从层次 n 到层次 l 的位置 (i,j) 处的特征向量为 $x_{ij}^{n \rightarrow l}$ ，经过自适应空间融合后得到的结果特征向量 y_{ij}^l ，通过如下线性组合公式确定：

$$y_{ij}^l = \alpha_{ij}^l \cdot x_{ij}^{1 \rightarrow l} + \beta_{ij}^l \cdot x_{ij}^{2 \rightarrow l} + \gamma_{ij}^l \cdot x_{ij}^{3 \rightarrow l} \quad (5.6)$$

其中， $\alpha_{ij}^l, \beta_{ij}^l$ 和 γ_{ij}^l 代表层次 l 上三个层次特征的空间权重，且满足约束条件 $\alpha_{ij}^l + \beta_{ij}^l + \gamma_{ij}^l = 1$ 。这表明在每个空间位置 (i,j) ，三个层次的特征向量 $x_{ij}^{1 \rightarrow l}, x_{ij}^{2 \rightarrow l}$ 和 $x_{ij}^{3 \rightarrow l}$ 依据各自对应的权重进行线性组合，最终得到融合后的特征向量 y_{ij}^l 。权重的分配会根据不同层次特征在该位置对检测目标的重要性动态调整，从而突出关键特征，抑制矛盾信息，实现更高效的特征融合。

(便于编辑，后续补 AFPN 结构图)

5.2.3 轻量化主干网络

Yolov8 主干网络中的 CSPDarknet53 通过跨阶段连接可以提升信息流和检测精度，但其计算需求较高，尤其在移动设备或嵌入式系统上可能导致延迟和能耗问题。考虑到中药饮片智能分拣领域里所使用的机械检测设备算力有限，本文采用 MobileNet 系列的 MobileNetV3 作为主干网络进行改进。MobileNetV3 是在前两个版本 MobileNetV1

和 MobileNetV2 的深度可分离卷积和倒置残差结构的基础上, 引入了 SE 注意力机制, 使模型在大幅减少参数量的同时保持一定的检测精度, 其主要网络结构

如图 () 所示。

MobileNetV3 的深度可分离卷积和倒置残差结构能减少浮点运算和参数数量, 这使得它在中药饮片检测的实时性和低功耗部署中具有优势。

5.2.3.1 基于 ECA 的轻量化改进

MobileNetV3 中的 DW 卷积操作在大大减少模型参数量的同时, 深度卷积与逐点卷积互相独立也会使得通道间的特征交互能力变差, 进而造成模型精度下降。为弥补这一缺陷, SE 注意力机制 (Squeeze-and-Excitation Networks, SE-Net) 被引入网络设计中^[33], 其核心思想是通过 Squeeze 模块和 Excitation 模块建模通道间的依赖关系, 自适应地为每个通道分配权重, 一方面增强重要通道的特征表达, 另一方面抑制冗余通道,

如图 (为加快编译器速度, 后续再补图) 所示,

SE 模块通过 Squeeze 操作做全局平均池化, 将输入特征图 ($H \times W \times C$) 转换为 ($1 \times 1 \times C$) 的通道描述向量, 捕捉全局信息。然后在 Excitation 模块使用两个全连接层 (FC) 对 ($1 \times 1 \times C$) 的通道描述向量进行非线性交互, 通过第一个 FC+Relu 函数将其调整至维度为 $C/4$ 的特征图, 经过第二个 FC+hard-sigmoid 函数将其调整至维度为 ($1, 1, C$) 的特征图, 然后与原特征图每个通道对应相乘, 从而实现对原始特征图每个通道的权重调整。整个过程公式化表示为:

$$\mathbf{F}_{SE} = \sigma(\mathbf{W}_2 \delta(\mathbf{W}_1 \mathbf{z})) \odot \mathbf{F}_{DWConv} \quad (5.7)$$

其中 $\mathbf{z} \in \mathbb{R}^C$ 为全局平均池化 (GAP) 生成的通道描述向量, $\mathbf{W}_1 \in \mathbb{R}^{C/r \times C}$ 和 $\mathbf{W}_2 \in \mathbb{R}^{C \times C/r}$ 为全连接层权重矩阵, $\odot$ 表示逐通道相乘。

然而, SE 模块的设计存在显著的参数量问题, 单个 SE 模块参数量的计算公式如下:

$$\mathcal{P}_{SE} = \frac{2C^2}{r} \quad (5.8)$$

其中 C 是输入通道数, $r =$ 为压缩比, 以 MobileNetV3-large 中 $C = 256$ 的典型中间层为例, 当 $r=16$ 时, 单个 SE 模块参数量高达 8192, 而网络中通常包含 5-7 个 SE 模块, 这显著增加了模型复杂度。此外, 全连接层强制性的通道降维可能导致通道间交互信息的损失, 限制了注意力机制的表达能力。针对上述问题, ECA-Net (Efficient Channel Attention Network) 提出了一种轻量化的改进方案。ECA 模块摒弃了 SE 中复杂的全连接结构, 转而采用一维卷积直接捕获跨通道交互信息^[34]。

(如图所示) 其核心公式如下:

$$ECA(x) = x \cdot \sigma(\text{Conv1D}(\text{GAP}(x))) \quad (5.9)$$

其中, GAP 为全局平均池化, Conv1D 为自适应卷积核的一维卷积, σ 为 Sigmoid 函数。

这个设计包含两个关键优化: 首先, 取消 SE 中的通道压缩 ($C/r \rightarrow C$), 直接在一维卷积中捕获跨通道交互, 通过保留完整通道维度避免信息损失; 其次, 引入自适应卷积核机制, 根据通道数 C 动态确定一维卷积核大小 k , 确保不同规模的特征图均能有效建模局部跨通道依赖, 其数学公式为:

$$k = \left\lfloor \frac{\log_2 C}{\gamma} + \frac{b}{\gamma} \right\rfloor_{\text{odd}} \quad (5.10)$$

其中 $\gamma = 2$, $b = 1$ 保证 k 为奇数。此时参数量降为:

$$\mathcal{P}_{ECA} = k \times C \quad (5.11)$$

以 $C = 256$, $k = 3$ 为例, $\mathcal{P}_{ECA} = 768$, 参数量较 SE 模块减少 90.6%

5.2.3.2 替换激活函数

为了可以充分地处理复杂图像数据中的高维特征, 网络模型引入激活函数以此实现数据的去线性化以及非线性性。在 MobileNetV3 中将 SE 替换为轻量级 ECA 之后, 模块的激活函数就是 ECA 原本的 Simoid 函数, 其数学公式如下:

$$f(x) = \frac{1}{1 + e^{-x}} \quad (5.12)$$

可以看到, 尽管 ECA 的一维卷积计算很高效, 但 Sigmoid 函数执行指数运算, 比较消耗计算资源, 并且在反向传播中由于函数饱和存在使梯度消失问题。对此, 我们将其替换为 HardSigmoid 激活函数, 其表达式分别为:

$$\text{Hardsigmoid} = \begin{cases} 0 & x \leq -3 \\ 1 & x \geq 3 \\ \frac{x}{6} + \frac{1}{2} & \text{otherwise} \end{cases} \quad (5.13)$$

可以看到, HSigmoid 是基于 ReLU6 的分段线性函数, 输出范围为 $[0,1]$, 可以用于替换模拟 Sigmoid 的归一化, 并且仅需加减、比较和除法操作, 计算量大幅降低。

5.2.4 改进后的整体网络架构

第六章 总结和展望

6.1 总结

6.2 展望

参考文献

- [1] HUNTE B, MARIN J, STONE P J. Experiments in induction.[J]. 1966.
- [2] 兰济乐, 丁舒飞, 邱璐琦, 等. 中药治疗癫痫的成方规律分析[J]. 中成药, 2020, 42(08): 2156-2160.
- [3] 钱丹丹, 周金海. 基于计算机视觉的中药饮片检测与分级研究[J]. 时珍国医国药, 2019, 30(01): 203-205.
- [4] COVER T, HART P. Nearest neighbor pattern classification[J]. IEEE transactions on information theory, 1967, 13(1): 21-27.
- [5] 王新洲, 朱永亮, 金若敏, 等. 基于数学模型的药物成分肾毒性预测[J]. 中国新药杂志, 2014, 23(13): 1565-1568+1578.
- [6] CORTES C, VAPNIK V. Support-vector networks[J]. Machine learning, 1995, 20: 273-297.
- [7] 孙鑫, 钱会南. 基于深度卷积网络的中药饮片图像识别[J]. 世界科学技术-中医药现代化, 2017, 19(02): 218-222.
- [8] 徐飞, 孟沙, 吴启南, 等. 基于卷积神经网络的人参与西洋参饮片鉴别方法研究[J]. 南京中医药大学学报, 2018, 34(06): 621-624. DOI: 10.14148/j.issn.1672-0482.2018.0621.
- [9] 刘伟, 邹伟红, 卢彦杰, 等. 基于迁移学习和模型融合的中药材图像识别研究[J]. 湖南中医药大学学报, 2022, 42(05): 809-814.
- [10] 史婷婷, 张小波, 郭兰萍, 等. 基于深度卷积神经网络的仿野生种植金银花遥感识别方法研究[J]. 中国中药杂志, 2020, 45(23): 5658-5662. DOI: 10.19540/j.cnki.cjcmm.20200927.103.
- [11] LECUN Y, BOTTOU L, BENGIO Y, et al. Gradient-based learning applied to document recognition [J]. Proceedings of the IEEE, 1998, 86(11): 2278-2324.
- [12] KRIZHEVSKY A, SUTSKEVER I, HINTON G E. ImageNet classification with deep convolutional neural networks[J]. Communications of the ACM, 2017, 60(6): 84-90.
- [13] SIMONYAN K, ZISSERMAN A. Very deep convolutional networks for large-scale image recognition[J]. arXiv preprint arXiv:1409.1556, 2014.
- [14] SZEGEDY C, LIU W, JIA Y, et al. Going deeper with convolutions[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2015: 1-9.
- [15] HE K, ZHANG X, REN S, et al. Deep residual learning for image recognition[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 770-778.
- [16] HASSAN S M, MAJI A K. Plant disease identification using a novel convolutional neural network [J]. IEEE access, 2022, 10: 5390-5401.
- [17] BAE J B, LEE S, JUNG W, et al. Identification of Alzheimer's disease using a convolutional neural network model based on T1-weighted magnetic resonance imaging[J]. Scientific reports, 2020, 10(1): 22252.
- [18] 许景辉, 邵明烨, 王一琛, 等. 基于迁移学习的卷积神经网络玉米病害图像识别[J]. 农业机械学报, 2020, 51(2): 230-236.

- [19] 傅隆生, 冯亚利, TOLA E, 等. 基于卷积神经网络的田间多簇猕猴桃图像识别方法[J]. 农业工程学报, 2018, 34(2): 205-211.
- [20] 孙鑫, 钱会南. 基于深度卷积网络的中药饮片图像识别[J]. 世界科学技术: 中医药现代化, 2017, 19(2): 218-222.
- [21] 吴冲, 谭超群, 黄永亮, 等. 基于深度学习算法的川贝母, 山楂及半夏饮片的智能鉴别[J]. 中国实验方剂学杂志, 2020, 26(21): 195-201.
- [22] 徐飞, 孟沙, 吴启南, 等. 基于卷积神经网络的人参与西洋参饮片鉴别方法研究[J]. 南京中医药大学学报, 2018, 34(6): 621-624.
- [23] 王健庆, 戴恺, 李子柔. 基于深度学习的中药饮片图像识别研究[J]. 时珍国医国药, 2020.
- [24] 张怡昕, 刘明月, 郑乐兵, 等. 基于卷积神经网络的大黄饮片的识别研究[J]. 现代信息科技, 2021, 5(03): 72-74+78. DOI: 10.19850/j.cnki.2096-4706.2021.03.019.
- [25] 李国辰, 赵晓, 王若男, 等. 基于改进卷积神经网络的中药饮片图像识别[J]. 科学技术与工程, 2024, 24(9): 3596-3604.
- [26] MNIH V, HEES N, GRAVES A, et al. Recurrent models of visual attention[J]. Advances in neural information processing systems, 2014, 27.
- [27] GIRSHICK R, DONAHUE J, DARRELL T, et al. Rich feature hierarchies for accurate object detection and semantic segmentation[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2014: 580-587.
- [28] DAI J, LI Y, HE K, et al. R-fcn: Object detection via region-based fully convolutional networks[J]. Advances in neural information processing systems, 2016, 29.
- [29] CAI Z, VASCONCELOS N. Cascade r-cnn: Delving into high quality object detection[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 6154-6162.
- [30] PANG J, CHEN K, SHI J, et al. Libra r-cnn: Towards balanced learning for object detection[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2019: 821-830.
- [31] QI Y, HE Y, QI X, et al. Dynamic snake convolution based on topological geometric constraints for tubular structure segmentation[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2023: 6070-6079.
- [32] YANG G, LEI J, ZHU Z, et al. AFPN: Asymptotic feature pyramid network for object detection[C]//2023 IEEE International Conference on Systems, Man, and Cybernetics (SMC). 2023: 2184-2189.
- [33] HU J, SHEN L, SUN G. Squeeze-and-excitation networks[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 7132-7141.
- [34] WANG Q, WU B, ZHU P, et al. ECA-Net: Efficient channel attention for deep convolutional neural networks[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2020: 11534-11542.

致谢

致谢部分...

img/lwsm_180xxxxxxx.pdf